

## Práctica3 - Predicción Ventas Apple

Manuel Carmona Cabello de Alba

25 de noviembre de 2017

Cargamos las librerías que vamos a utilizar:

```
library(quantmod) #Package to download financials historical data
## Warning: package 'quantmod' was built under R version 3.4.2
## Loading required package: xts
## Warning: package 'xts' was built under R version 3.4.2
## Loading required package: zoo
## Warning: package 'zoo' was built under R version 3.4.2
##
## Attaching package: 'zoo'
##
## The following objects are masked from 'package:base':
##
##   as.Date, as.Date.numeric
## Loading required package: TTR
## Warning: package 'TTR' was built under R version 3.4.2
## Version 0.4-0 included new data defaults. See ?getSymbols.
library(moments) # Calculate Kurtosis and skewness
library(ggplot2) #Plot Library
## Warning: package 'ggplot2' was built under R version 3.4.2
library(ggfortify) #Plot Monthplot
library(plyr) #Using ddply with data.frames
## Warning: package 'plyr' was built under R version 3.4.2
library(zoo)
require(forecast)
## Loading required package: forecast
## Warning: package 'forecast' was built under R version 3.4.2
##
## Attaching package: 'forecast'
```

```
## The following object is masked from 'package:ggfortify':  
##  
##      ggdiagplot  
  
require(xts)  
library(base)  
library(tseries)  
  
## Warning: package 'tseries' was built under R version 3.4.2  
  
library(forcats)  
  
## Warning: package 'forcats' was built under R version 3.4.2  
  
library(timsac)  
library(TSA)  
  
## Warning: package 'TSA' was built under R version 3.4.2  
  
## Loading required package: leaps  
  
## Warning: package 'leaps' was built under R version 3.4.2  
  
## Loading required package: locfit  
  
## Warning: package 'locfit' was built under R version 3.4.2  
  
## locfit 1.5-9.1      2013-03-22  
  
## Loading required package: mgcv  
  
## Loading required package: nlme  
  
##  
## Attaching package: 'nlme'  
  
## The following object is masked from 'package:forecast':  
##  
##      getResponse  
  
## This is mgcv 1.8-17. For overview type 'help("mgcv-package")'.  
  
##  
## Attaching package: 'TSA'  
  
## The following objects are masked from 'package:moments':  
##  
##      kurtosis, skewness  
  
## The following objects are masked from 'package:stats':  
##  
##      acf, arima
```

```
## The following object is masked from 'package:utils':
##
##      tar

library(e1071)

## Warning: package 'e1071' was built under R version 3.4.2

##
## Attaching package: 'e1071'

## The following objects are masked from 'package:TSA':
##
##      kurtosis, skewness

## The following objects are masked from 'package:moments':
##
##      kurtosis, moment, skewness

library(ggthemes)

## Warning: package 'ggthemes' was built under R version 3.4.2

library(reader)

## Warning: package 'reader' was built under R version 3.4.2

## Loading required package: NCmisc

## Warning: package 'NCmisc' was built under R version 3.4.2

##
## Attaching package: 'NCmisc'

## The following object is masked from 'package:nlme':
##
##      Dim

library(gridExtra)

## Warning: package 'gridExtra' was built under R version 3.4.2
```

Cargamos los datos y los visualizamos

```
datos <- read.csv("C:/Users/Manuel/Desktop/CUNEF/Prediccion/Clase05/Datos
/apple.csv", header=T, sep=",")
datos<-datos[-1,]
datos[is.na(datos)]<-0
datos$totalsales<-datos$iPhone+datos$iPad+datos$iPod+datos$Mac
datos
```

		Time Period	iPhone	iPad	iPod	Mac	totalsales	
##	2	Q1/99	2	0.000	0.000	0.000	0.827	0.827
##	3	Q2/99	3	0.000	0.000	0.000	0.905	0.905

## 4	Q3/99	4	0.000	0.000	0.000	0.772	0.772
## 5	Q4/99	5	0.000	0.000	0.000	1.377	1.377
## 6	Q1/00	6	0.000	0.000	0.000	1.043	1.043
## 7	Q2/00	7	0.000	0.000	0.000	1.016	1.016
## 8	Q3/00	8	0.000	0.000	0.000	1.122	1.122
## 9	Q4/00	9	0.000	0.000	0.000	0.659	0.659
## 10	Q1/01	10	0.000	0.000	0.000	0.751	0.751
## 11	Q2/01	11	0.000	0.000	0.000	0.827	0.827
## 12	Q3/01	12	0.000	0.000	0.000	0.850	0.850
## 13	Q4/01	13	0.000	0.000	0.125	0.746	0.871
## 14	Q1/02	14	0.000	0.000	0.062	0.813	0.875
## 15	Q2/02	15	0.000	0.000	0.054	0.808	0.862
## 16	Q3/02	16	0.000	0.000	0.140	0.734	0.874
## 17	Q4/02	17	0.000	0.000	0.219	0.743	0.962
## 18	Q1/03	18	0.000	0.000	0.080	0.711	0.791
## 19	Q2/03	19	0.000	0.000	0.304	0.771	1.075
## 20	Q3/03	20	0.000	0.000	0.336	0.787	1.123
## 21	Q4/03	21	0.000	0.000	0.733	0.829	1.562
## 22	Q1/04	22	0.000	0.000	0.807	0.749	1.556
## 23	Q2/04	23	0.000	0.000	0.860	0.876	1.736
## 24	Q3/04	24	0.000	0.000	2.016	0.836	2.852
## 25	Q4/04	25	0.000	0.000	4.580	1.046	5.626
## 26	Q1/05	26	0.000	0.000	5.311	1.070	6.381
## 27	Q2/05	27	0.000	0.000	6.155	1.182	7.337
## 28	Q3/05	28	0.000	0.000	6.451	1.236	7.687
## 29	Q4/05	29	0.000	0.000	14.043	1.254	15.297
## 30	Q1/06	30	0.000	0.000	8.526	1.112	9.638
## 31	Q2/06	31	0.000	0.000	8.111	1.327	9.438
## 32	Q3/06	32	0.000	0.000	8.729	1.610	10.339
## 33	Q4/06	33	0.000	0.000	21.066	1.606	22.672
## 34	Q1/07	34	0.000	0.000	10.549	1.517	12.066
## 35	Q2/07	35	0.270	0.000	9.815	1.764	11.849
## 36	Q3/07	36	1.119	0.000	10.200	2.164	13.483
## 37	Q4/07	37	2.315	0.000	22.121	2.319	26.755
## 38	Q1/08	38	1.703	0.000	10.644	2.289	14.636
## 39	Q2/08	39	0.717	0.000	11.011	2.496	14.224
## 40	Q3/08	40	6.892	0.000	11.052	2.611	20.555
## 41	Q4/08	41	4.363	0.000	22.727	2.524	29.614
## 42	Q1/09	42	3.793	0.000	11.013	2.216	17.022
## 43	Q2/09	43	5.208	0.000	10.215	2.603	18.026
## 44	Q3/09	44	7.367	0.000	10.177	3.053	20.597
## 45	Q4/09	45	8.737	0.000	20.970	3.362	33.069
## 46	Q1/10	46	8.752	0.000	10.885	2.943	22.580
## 47	Q2/10	47	8.398	3.270	9.406	3.472	24.546
## 48	Q3/10	48	14.102	4.188	9.051	3.885	31.226
## 49	Q4/10	49	16.235	7.331	19.446	4.134	47.146
## 50	Q1/11	50	18.647	4.694	9.017	3.760	36.118
## 51	Q2/11	51	20.338	9.246	7.535	3.947	41.066
## 52	Q3/11	52	17.073	11.123	6.622	4.894	39.712
## 53	Q4/11	53	37.044	15.434	15.397	5.198	73.073

```
## 54 Q1/12      54 35.064 11.798  7.673 4.017      58.552
## 55 Q2/12      55 26.028 17.042  6.751 4.020      53.841
## 56 Q3/12      56 26.910 14.036  5.344 4.923      51.213
## 57 Q4/12      57 47.789 22.860 12.679 4.061      87.389
## 58 Q1/13      58 37.430 19.477  5.633 3.952      66.492
## 59 Q2/13      59 31.241 14.617  4.569 3.754      54.181
## 60 Q3/13      60 33.797 14.079  3.498 4.574      55.948
## 61 Q4/13      61 51.025 26.035  6.049 4.837      87.946
## 62 Q1/14      62 43.719 16.350  2.761 4.136      66.966
## 63 Q2/14      63 35.203 13.276  2.926 4.413      55.818
## 64 Q3/14      64 39.272 12.316  2.641 5.520      59.749
## 65 Q4/14      65 74.468 21.419  0.000 5.519     101.406
## 66 Q1/15      66 61.170 12.623  0.000 4.563      78.356
## 67 Q2/15      67 47.534 10.931  0.000 4.796      63.261
## 68 Q3/15      68 48.050  9.880  0.000 5.710      63.640
## 69 Q4/15      69 74.780 16.120  0.000 5.310      96.210
## 70 Q1/16      70 51.200 10.250  0.000 4.030      65.480
```

Cambiamos el formato para poder trabajar con los datos como serie temporal

```
library(zoo)
datos$Time<-as.Date(as.yearqtr(datos$Time, format="Q%q/%y"))
str(datos$Time)

##  Date[1:69], format: "1999-01-01" "1999-04-01" "1999-07-01" "1999-10-0
1" "2000-01-01" ...

xVentas=xts((datos$totalsales),order.by=datos$Time) #La y mayuscula porqu
e esta el a?o completo

#Generate quarterly data
xVentas=to.quarterly(xVentas)

#Transform to zoo data (forecast package)
zVentas=as.zoo(xVentas$xVentas.Close)
```

Pasamos el nombre a Ventas totales

```
names(zVentas)="Ventas_totales"
zVentas

##           Ventas_totales
## 1999 Q1              0.827
## 1999 Q2              0.905
## 1999 Q3              0.772
## 1999 Q4              1.377
## 2000 Q1              1.043
## 2000 Q2              1.016
## 2000 Q3              1.122
## 2000 Q4              0.659
## 2001 Q1              0.751
```

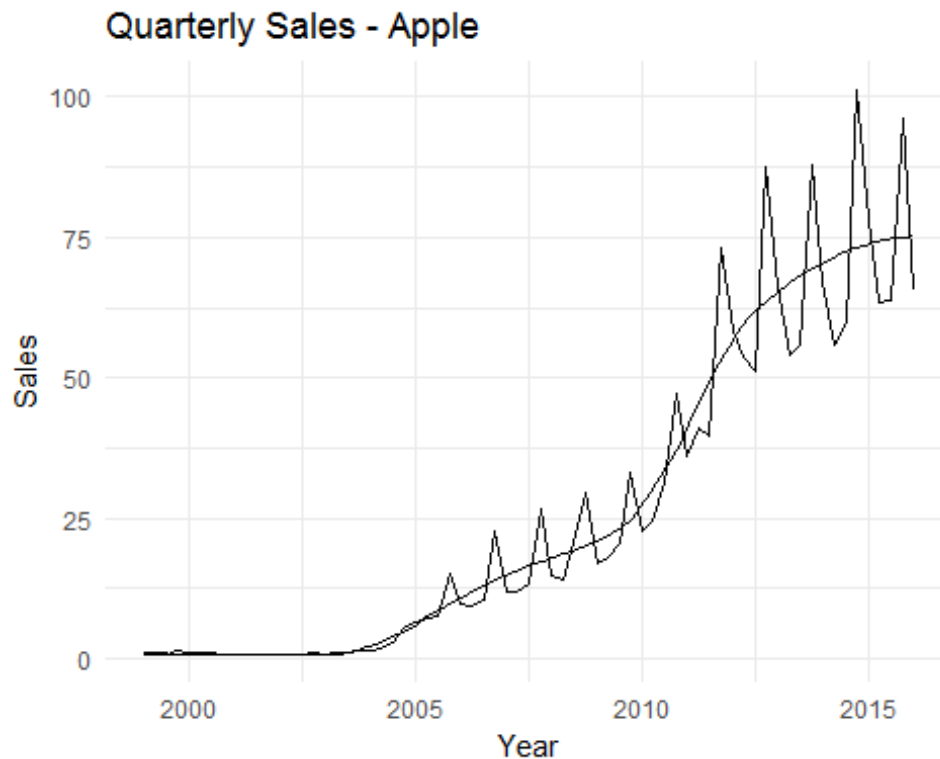
##	2001	Q2	0.827
##	2001	Q3	0.850
##	2001	Q4	0.871
##	2002	Q1	0.875
##	2002	Q2	0.862
##	2002	Q3	0.874
##	2002	Q4	0.962
##	2003	Q1	0.791
##	2003	Q2	1.075
##	2003	Q3	1.123
##	2003	Q4	1.562
##	2004	Q1	1.556
##	2004	Q2	1.736
##	2004	Q3	2.852
##	2004	Q4	5.626
##	2005	Q1	6.381
##	2005	Q2	7.337
##	2005	Q3	7.687
##	2005	Q4	15.297
##	2006	Q1	9.638
##	2006	Q2	9.438
##	2006	Q3	10.339
##	2006	Q4	22.672
##	2007	Q1	12.066
##	2007	Q2	11.849
##	2007	Q3	13.483
##	2007	Q4	26.755
##	2008	Q1	14.636
##	2008	Q2	14.224
##	2008	Q3	20.555
##	2008	Q4	29.614
##	2009	Q1	17.022
##	2009	Q2	18.026
##	2009	Q3	20.597
##	2009	Q4	33.069
##	2010	Q1	22.580
##	2010	Q2	24.546
##	2010	Q3	31.226
##	2010	Q4	47.146
##	2011	Q1	36.118
##	2011	Q2	41.066
##	2011	Q3	39.712
##	2011	Q4	73.073
##	2012	Q1	58.552
##	2012	Q2	53.841
##	2012	Q3	51.213
##	2012	Q4	87.389
##	2013	Q1	66.492
##	2013	Q2	54.181
##	2013	Q3	55.948

```
## 2013 Q4      87.946
## 2014 Q1      66.966
## 2014 Q2      55.818
## 2014 Q3      59.749
## 2014 Q4     101.406
## 2015 Q1      78.356
## 2015 Q2      63.261
## 2015 Q3      63.640
## 2015 Q4      96.210
## 2016 Q1      65.480
```


Vamos a ver la serie

```
apple.plot <- autoplot(as.ts(zVentas), ts.colour="dodgerblue3")+
  labs(y="Sales",x="Year")+
  ggtitle("Quarterly Sales - Apple")+
  theme_minimal()+
  geom_smooth(aes(y=(zVentas)),span=0.35,se=F,size=0.4,col="black")
apple.plot

## `geom_smooth()` using method = 'loess'
```




```
ggfreqplot(as.ts(zVentas),freq=4,nrow=1,facet.labeller=c("1Q","2Q","3Q","4Q"))+ggtitle("Quarterly sales")
```



Podemos observar que el cuarto trimestre del año es el que lidera las ventas, coincidiendo con la política de lanzamiento de productos de Apple.

```
library(ggplot2)
ggplot(datos, aes(x=Time, y=totalsales)) + geom_col()
```





En este gráfico

corroboramos la anterior afirmación

Descripción de la serie: Tendencia: tiene tendencia positiva, no queda claro si es lineal o exponencial (componente aditivo o multiplicativo) y no tiene ciclo. Estacionalidad: Claramente existe componente estacional multiplicativo, como puede observarse en el primer trimestre de cada año. La serie es no estacionaria en varianza y EN MEDIA????

## Modelos ETS

Los modelos ETS solo asumen datos no estacionarios. Así, no tenemos que transformar la serie para estimar los modelos. Dentro de los modelos ETS, los que incluyen el componente estacional son los llamados Holt-Winters. Vamos a estimar 4 modelos Holt-Winter y seleccionaremos uno en función de los criterios AIC, BIC y HQ.

## Periodo entrenamiento y periodo test

Vamos a coger un periodo de entrenamiento y uno de test para probar el modelo

```
cOmit=4
nObs=length(zVentas)
oVentas <- window(zVentas, start=index(zVentas[1]), end=index(zVentas[nObs -
cOmit]))
```

Modelo Holt-Winter (A,M)

```

fitHWAM <- holt(oVentas, exponential=FALSE, damped=FALSE, seasonal="multiplicative")
fitHWAM$model

## Holt's method
##
## Call:
## holt(y = oVentas, damped = FALSE, exponential = FALSE, seasonal = "multiplicative")
##
## Smoothing parameters:
##   alpha = 0.1959
##   beta  = 0.0258
##
## Initial states:
##   l = 0.4765
##   b = -0.0383
##
## sigma: 9.1891
##
##      AIC      AICc      BIC
## 569.6772 570.6941 580.5491

```

#### Modelo Holt-Winter (Ad,M)

```

fitHWAdM <- holt(oVentas,exponential=FALSE, damped=TRUE, seasonal="multiplicative")
fitHWAdM$model

## Damped Holt's method
##
## Call:
## holt(y = oVentas, damped = TRUE, exponential = FALSE, seasonal = "multiplicative")
##
## Smoothing parameters:
##   alpha = 0.1171
##   beta  = 0.117
##   phi   = 0.8634
##
## Initial states:
##   l = 1.212
##   b = 0.0469
##
## sigma: 9.2475
##
##      AIC      AICc      BIC
## 572.5013 573.9496 585.5476

```

#### Modelo Holt-Winter (M,M)

```

fitHMMM <- holt(oVentas,exponential=TRUE, damped=FALSE, seasonal="multiplicative")
fitHMMM$model

## Holt's method with exponential trend
##
## Call:
## holt(y = oVentas, damped = FALSE, exponential = TRUE, seasonal = "multiplicative")
##
## Smoothing parameters:
##   alpha = 0.2217
##   beta  = 1e-04
##
## Initial states:
##   l = 1.8787
##   b = 1.0471
##
## sigma: 0.5055
##
##      AIC      AICc      BIC
## 472.4415 473.4585 483.3134

```

Modelo Holt-Winter(Md,M)

```

fitHWMdM <- holt(oVentas,exponential=TRUE, damped=TRUE, seasonal="multiplicative")
fitHWMdM$model

## Damped Holt's method with exponential trend
##
## Call:
## holt(y = oVentas, damped = TRUE, exponential = TRUE, seasonal = "multiplicative")
##
## Smoothing parameters:
##   alpha = 0.1192
##   beta  = 0.1192
##   phi   = 0.8
##
## Initial states:
##   l = 1.1602
##   b = 1.2634
##
## sigma: 0.412
##
##      AIC      AICc      BIC
## 442.3112 443.7595 455.3576

```

Como podemos observar, según los criterios de informacion los modelos aditivos funcionaron peor. Vamos a graficar los modelos para comprobarlo.

```

plot(fitHWAM,ylab="Ventas",
     plot.conf=FALSE, type="o", fcol="orange", xlab="Year")

## Warning in plot.window(xlim, ylim, log, ...): "plot.conf" is not a
## graphical parameter

## Warning in title(main = main, xlab = xlab, ylab = ylab, ...): "plot.co
nf"
## is not a graphical parameter

## Warning in axis(1, ...): "plot.conf" is not a graphical parameter

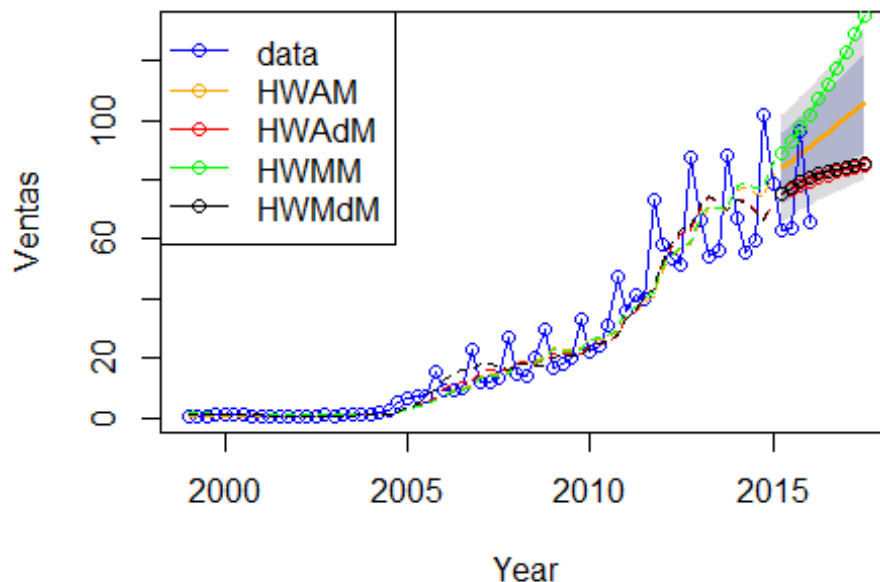
## Warning in axis(2, ...): "plot.conf" is not a graphical parameter

## Warning in box(...): "plot.conf" is not a graphical parameter

lines(window(zVentas),type="o",col="blue")
lines(fitted(fitHWAM), col="orange", lty=2)
lines(fitted(fitHWAdM), col="red", lty=2)
lines(fitted(fitHWMM), col="green", lty=2)
lines(fitted(fitHWMdM), col="black", lty=2)
lines(fitHWAdM$mean, type="o", col="red")
lines(fitHWMM$mean, type="o", col="green")
lines(fitHWMdM$mean, type="o", col="black")
legend("topleft",lty=1, pch=1, col=c("blue","orange", "red", "green", "bl
ack"),
      c("data","HWAM", "HWAdM", "HWMM", "HWMdM"))

```

### Forecasts from Holt's method



Ahora vamos a calcular el modelo de forma automatica:

```
etsfit<-ets(oVentas)
```

Vemos los coeficientes, la puntuaci?n en los criterios de informaci?n y las predicciones.

```
coef(etsfit) #esto returns all fitted parameters.
```

```
##      alpha      beta      gamma      l      b      s0
## 0.52328766 0.22725586 0.47671233 0.77769849 0.03445515 1.23396977
##      s1      s2
## 0.82714353 0.97243785
```

```
#forecast model
```

```
#forecast model
```

```
fventas.ets=forecast(etsfit, level=(c(75,25)))
```

```
#Results
```

```
summary(fventas.ets)
```


```
##
## Forecast method: ETS(M,A,M)
##
## Model Information:
## ETS(M,A,M)
##
## Call:
## ets(y = oVentas)
##
## Smoothing parameters:
##   alpha = 0.5233
##   beta  = 0.2273
##   gamma = 0.4767
##
## Initial states:
##   l = 0.7777
##   b = 0.0345
##   s=1.234 0.8271 0.9724 0.9664
##
## sigma: 0.197
##
##      AIC      AICc      BIC
## 353.4342 356.7070 373.0037
##
## Error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.08502138 3.165721 2.054496 0.2131736 14.01946 0.4254655
##              ACF1
## Training set -0.08122899
##
## Forecasts:
```

##		Point Forecast	Lo 25	Hi 25	Lo 75	Hi 75
##	2015 Q2	66.57793	62.39823	70.75764	51.48839	81.66747
##	2015 Q3	70.95723	65.41958	76.49488	50.96526	90.94920
##	2015 Q4	117.89441	106.37482	129.41400	76.30646	159.48236
##	2016 Q1	90.02745	79.16621	100.88869	50.81628	129.23862
##	2016 Q2	77.89727	65.10224	90.69231	31.70474	124.08980
##	2016 Q3	82.66843	67.00899	98.32786	26.13484	139.20201
##	2016 Q4	136.80562	107.10449	166.50676	29.57882	244.03243
##	2017 Q1	104.07810	78.36769	129.78852	11.25857	196.89764

Obtenemos un modelo con un AIC mucho menor que los anteriores. El modelo es de tipo M,A,M, es decir, de error multiplicativo, tendencia aditiva y componente estacional multiplicativo.

```
#plot(fventas.ets)
#lines(window(zVentas),type="o")

plotets <- autoplot(fventas.ets)+
  labs(y="Ventas",x="Tiempo")+
  ggtitle("Prediccion Modelo ETS (M,A,M)")+
  theme_minimal()+
  scale_colour_economist()+
  theme(legend.position = "bottom")
plotets
```



Como vemos, se ajusta mucho mejor que los modelos anteriormente calculados.

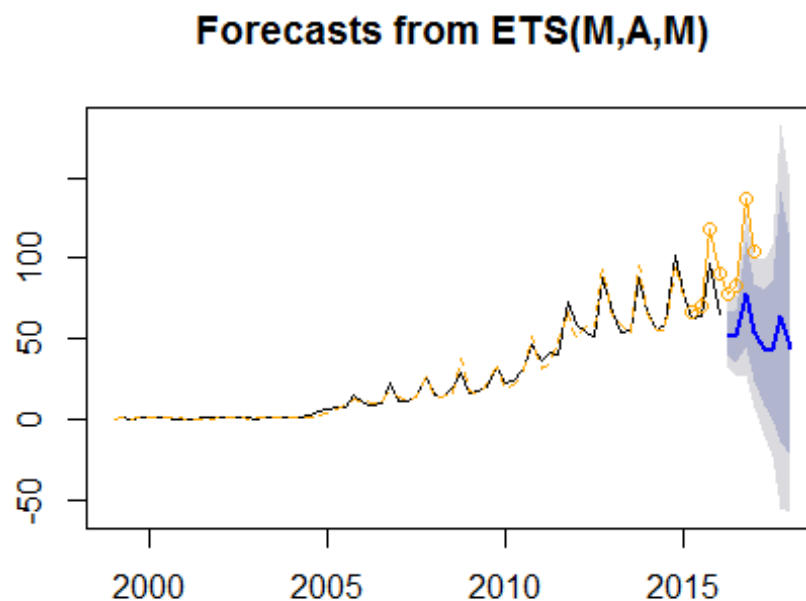
Ahora vamos a calcular los trimestres y los comparas con lo real, vemos que en el 4T es donde mas me alejo.

```
comparativa<-as.data.frame(matrix(c(fventas.ets$mean[1:cOmit],zVentas[(nObs-cOmit+1):nObs]),ncol=2))
names(comparativa)<-c("predicted","real")
comparativa

##   predicted   real
## 1  66.57793 63.261
## 2  70.95723 63.640
## 3 117.89441 96.210
## 4  90.02745 65.480
```


Ahora predecimos con todo para ver en el plot que es lo que hace el modelo y demostrar el caracter cortoplacista.

```
estfit2=ets(zVentas, damped=FALSE)
f.estfit2=forecast(estfit2)
plot(f.estfit2)
lines(fitted(fventas.ets), col="orange", lty=2)
lines(fventas.ets$mean, type="o", col="orange")
```



```
plotets <- autoplot(f.estfit2)+
  labs(y="Sales",x="Year")+
  ggtitle("Forecast TEST Modelo ETS (M,A,M)")+
  theme_minimal()+
  scale_colour_economist()+
```

```
theme(legend.position = "bottom")
plotets
```



## Modelos ARIMA

Como sabemos la serie es no estacionaria. Para hacerla estacionaria y poder utilizar los modelos ARIMA hemos de tranformarla en estacionaria.


## Análisis de la serie

El primer paso es hacerla estacionaria en varianza:

```
z1Ventas=log(zVentas)
df_new1 <- data.frame(value = as.vector(z1Ventas),
                      time = time(z1Ventas))
ggplot(df_new1)+geom_point(aes(x=time,y=value))+geom_line(aes(x=time,y=value))+ylab("Sales")+ggtitle("Quarterly Sales LOG Apple")+xlab("Quarter")

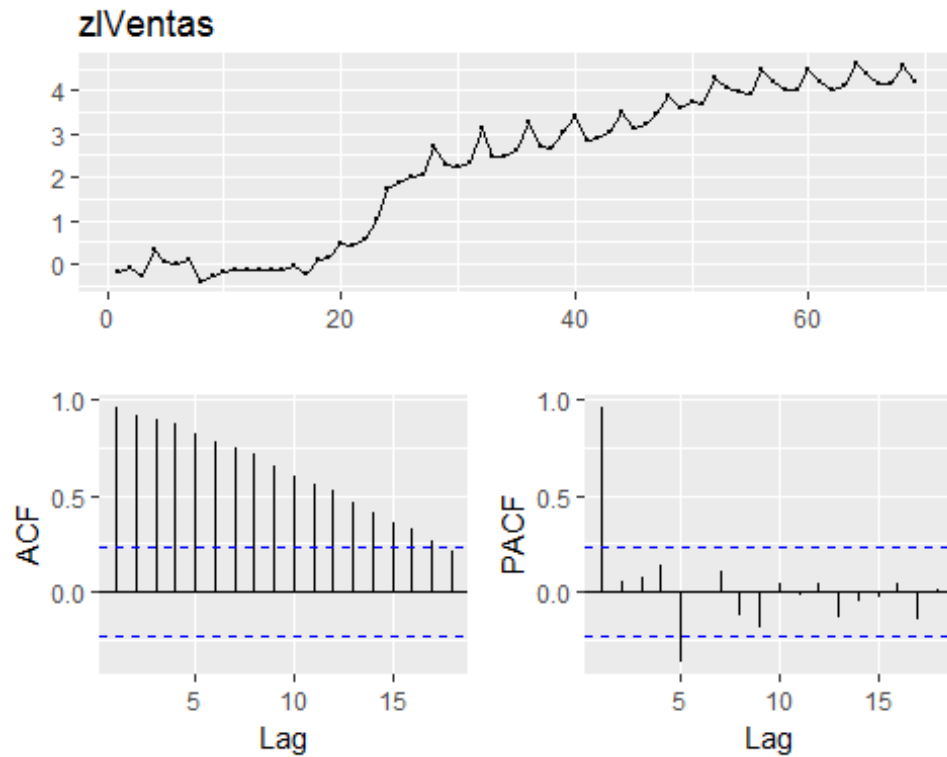
## Don't know how to automatically pick scale for object of type yearqtr.
Defaulting to continuous.
```





Ahora como vemos la serie es estacionaria en varianza tras aplicar la transformacion mas habitual, la logaritmica (logaritmo neperiano).


```
ggtsdisplay(zlVentas)
```



Claramente la serie es no estacionaria. Los valores de hoy dependen de los de hace 15 periodos.

Para transformar la serie a estacionaria en media, tenemos que aplicar el operador diferencias. Vamos a realizar la diferencia de primer orden, que consiste en restar a la serie original la misma serie pero retardar un periodo:

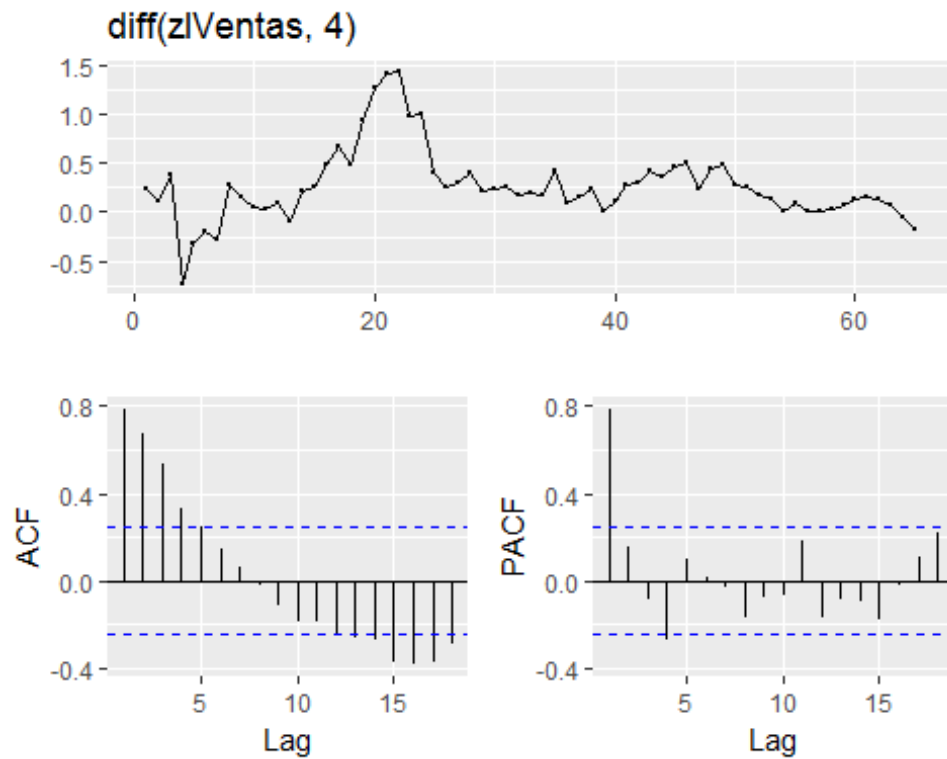
```
ggtsdisplay(diff(zlVentas)) #tasa intertrimestral, aunque parece estacionaria, si vemos la correlacion estacional en el grafico de abajo a la izq,
```



Con la diferencia obtenemos la tasa intertrimestral. Aunque parece estacionaria, si vemos la correlacion estacional en el grafico de abajo a la izquierda vemos que en la parte esacional no cae (barritas para arriba parecidas), por eso no es estacionaria.

Vamos a hacer la diferencia de orden 4 (anual)


```
ggtsdisplay(diff(zlVentas,4))
```



Aquí si observamos un ciclo y se ve que es estacionario.

Ahora haremos la segunda diferencia para ver como crece la tasa de variación anual a modo ilustrativo

```
ggtsdisplay(diff(diff(zlVentas,4),1))
```



Para ver como evoluciona la tasa de variación annual, hago una diferencia.

## Estimacion del modelo ARIMA

### Estimacion del modelo

Estimamos el modelo ARIMA con la funcion `auto.arima` y marcando `lambda=0` ya que queremos transformar la serie a estacionaria con la transformacion mas habitual, la logaritmica (logaritmo neperiano), que es un caso particular de la transformacion Box-Cox cuando el parametro `lambda` es cero.

```
fitARIMA=auto.arima(oVentas,lambda=0)
summary(fitARIMA)

## Series: oVentas
## ARIMA(1,0,0)(1,1,0)[4]
## Box Cox transformation: lambda= 0
##
## Coefficients:
##          ar1      sar1
##      0.9145  -0.3764
## s.e.  0.0478   0.1541
##
## sigma^2 estimated as 0.05184: log likelihood=3.75
## AIC=-1.51   AICc=-1.09   BIC=4.83
```

```
##
## Training set error measures:
##           ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.2063695 3.880316 2.350587 0.546513 14.85802 0.486783
##           ACF1
## Training set -0.1767947
```

Obtenemos un modelo SARIMA, ARIMA con componente estacional ARIMA(1,0,0)(1,1,0)[4]. El componente principal tiene componente autorregresivo de 1 retardo. El componente estacional igual, y adem?s requiere de una diferencia para hacer la serie estacionaria en media. Ninguno de los componentes depende de los errores que tuvieron lugar anteriormente. El [4] nos indica anualidad (4 trimestres) tal y como habiamos observado anteriormente aplicando las diferencias de forma manual para entender la serie.

Obtenemos un AIC mucho menor al que obteniamos con los modelos ETS. Esto tiene sentido puesto que los modelos ETS tienen un caracter cortoplacista muy marcado.

Vamos a probar estimandolo sin las funciones de aproximacion y stepwise de auto.arima, de forma que se exploren todos los modelos posibles.


```
fitARIMA2=auto.arima(oVentas,lambda=0, approximation = F, stepwise = F)
summary(fitARIMA2)

## Series: oVentas
## ARIMA(1,0,3)(0,1,1)[4] with drift
## Box Cox transformation: lambda= 0
##
## Coefficients:
##          ar1      ma1      ma2      ma3      sma1      drift
##          0.5535  0.1087  0.4203  0.7347 -0.1648  0.0741
## s.e.      0.1738  0.1573  0.1242  0.2120  0.2318  0.0254
##
## sigma^2 estimated as 0.0413:  log likelihood=11.26
## AIC=-8.52  AICc=-6.4  BIC=6.26
##
## Training set error measures:
##           ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.6010531 3.333167 2.089742 -2.192735 13.37792 0.4327646
##           ACF1
## Training set -0.01694753
```

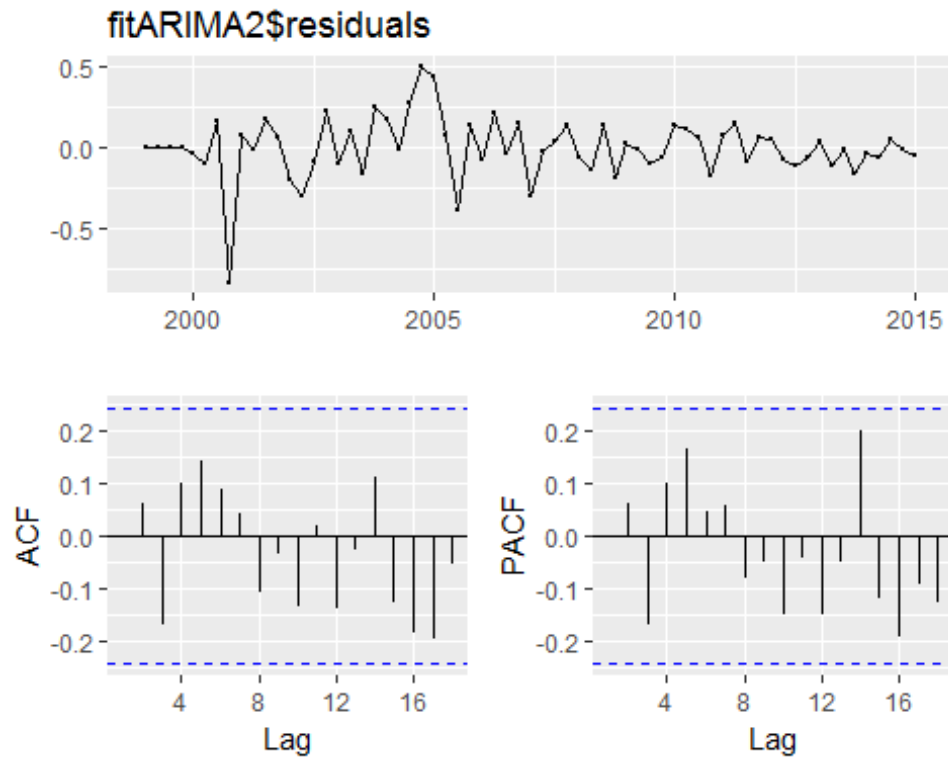
El modelo que se obtiene tiene mejor AIC pero peor BIC. Ante la duda, conviene comprobar como predicen ambos modelos.

## Analisis de residuos

```
ggtsdisplay(fitARIMA$residuals)
```



```
ggtsdisplay(fitARIMA2$residuals)
```



Prestando atención a las bandas vemos que los residuos se pueden calificar de ruido blanco. Aun así, vamos a realizar un test para comprobar que, efectivamente, los residuos son ruido blanco.

Realizaremos el test de Box-Ljung, que consiste en contrastar si los retardos de la acf son cero a la vez:

```
Box.test(fitARIMA$residuals,lag=4, fitdf=3, type="Lj")

##
## Box-Ljung test
##
## data: fitARIMA$residuals
## X-squared = 5.0026, df = 1, p-value = 0.02531

Box.test(fitARIMA$residuals,lag=8, fitdf=3, type="Lj")

##
## Box-Ljung test
##
## data: fitARIMA$residuals
## X-squared = 9.5764, df = 5, p-value = 0.08817

Box.test(fitARIMA$residuals,lag=12, fitdf=3, type="Lj")

##
## Box-Ljung test
##
## data: fitARIMA$residuals
## X-squared = 14.735, df = 9, p-value = 0.09847

Box.test(fitARIMA2$residuals,lag=4, fitdf=3, type="Lj")

##
## Box-Ljung test
##
## data: fitARIMA2$residuals
## X-squared = 2.9448, df = 1, p-value = 0.08615

Box.test(fitARIMA2$residuals,lag=8, fitdf=3, type="Lj")

##
## Box-Ljung test
##
## data: fitARIMA2$residuals
## X-squared = 5.9693, df = 5, p-value = 0.3092

Box.test(fitARIMA2$residuals,lag=12, fitdf=3, type="Lj")

##
## Box-Ljung test
##
```



```
## data: fitARIMA2$residuals
## X-squared = 9.0738, df = 9, p-value = 0.4305
```

H0: ruido blanco, H1: no es ruido blanco. En ambos modelos podemos considerar que los residuos son ruido blanco. `fitdf` es el número de parámetros que hemos estimado para obtener los residuos.

Vamos a ver como predicen ambos modelos.

Primero estimamos las predicciones

```
fventas.arima=forecast(fitARIMA)
fventas.arima=forecast(fitARIMA, level=c(70,90)) #podemos cambiar el intervalo

fventas.arima2=forecast(fitARIMA2, level=c(70,90))
```

Creamos un dataframe con la serie (`zVentas`) para poder representar el comportamiento del modelo y Graficamos:


```
df_new1<- data.frame(value = as.vector(zVentas),
                     time = time(zVentas))

ggplot(df_new1)+geom_point(aes(x=time,y=value))+geom_line(aes(x=time,y=value))+
  geom_forecast(fventas.arima,alpha=0.4)+ggtitle("ARIMA: Apple Forecast")

## Warning in geom_forecast(fventas.arima, alpha = 0.4): Use autolayer instead
## of geom_forecast to add a forecast layer to your ggplot object.

## Don't know how to automatically pick scale for object of type yearqtr.
## Defaulting to continuous.
```


## ARIMA: Apple Forecast



```
ggplot(df_new1)+geom_point(aes(x=time,y=value))+geom_line(aes(x=time,y=value))+ geom_forecast(fventas.arima2,alpha=0.4)+ggtitle("ARIMA2: Apple Forecast")
```

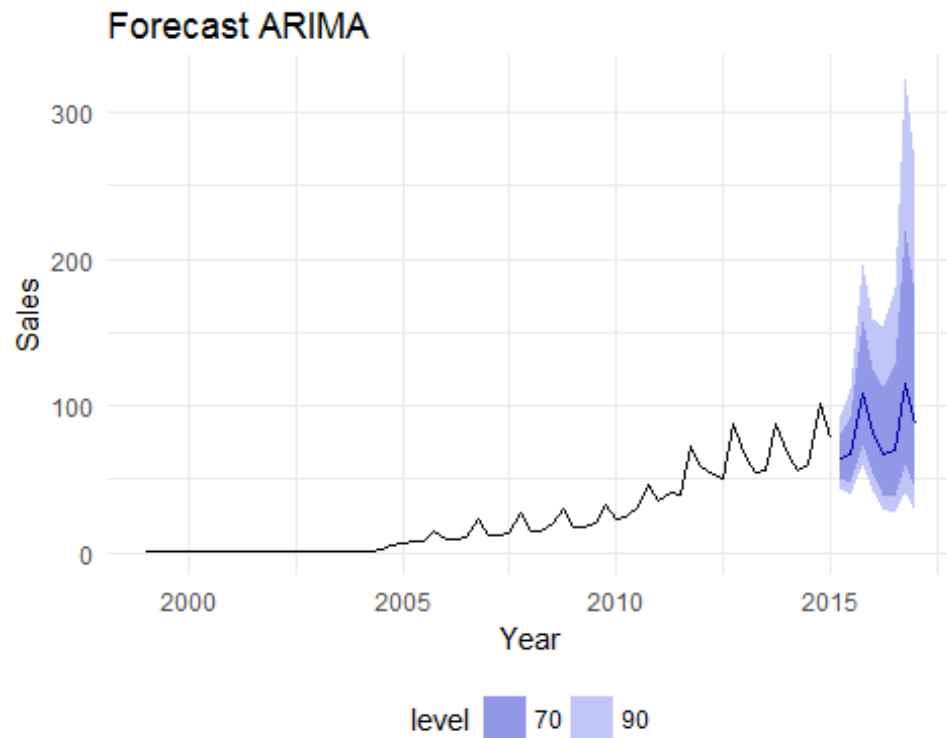
```
## Warning in geom_forecast(fventas.arima2, alpha = 0.4): Use autolayer
## instead of geom_forecast to add a forecast layer to your ggplot object
.
```

```
## Don't know how to automatically pick scale for object of type yearqtr.
Defaulting to continuous.
```

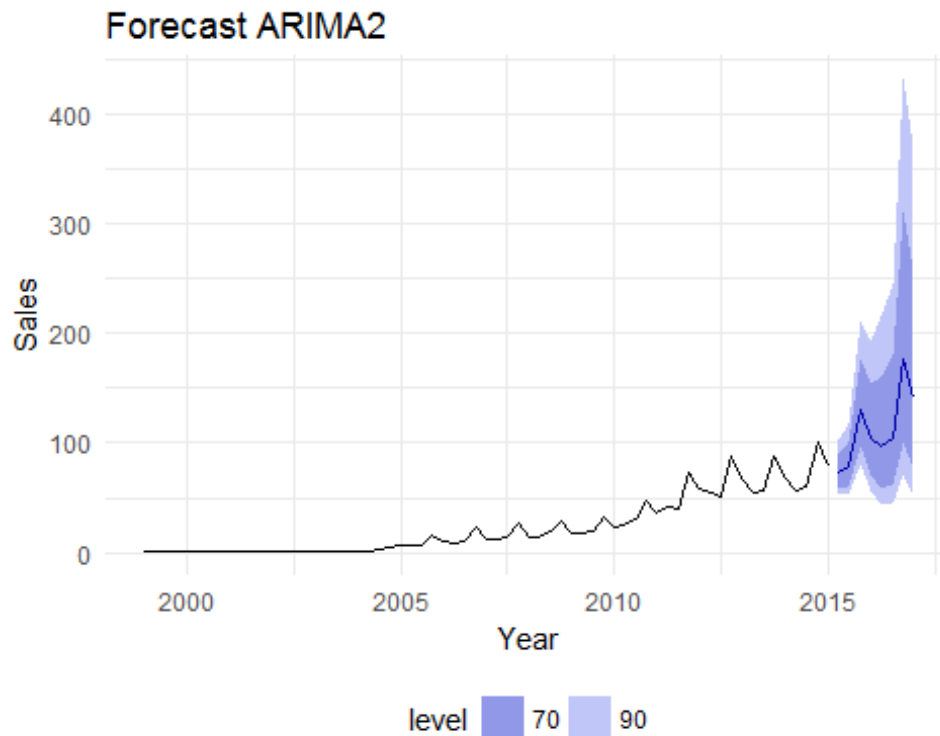


Con autoplot:

```
plotarima <- autoplot(fventas.arima)+  
  labs(y="Sales",x="Year")+  
  ggtitle("Forecast ARIMA")+  
  theme_minimal()+  
  scale_color_economist()+  
  theme(legend.position = "bottom")  
plotarima
```



```
plotarima2 <- autoplot(fventas.arima2)+  
  labs(y="Sales",x="Year")+  
  ggtitle("Forecast ARIMA2")+  
  theme_minimal()+  
  scale_color_economist()+  
  theme(legend.position = "bottom")  
plotarima2
```



La prediccion es la linea azul. Vemos la clara diferencia entre ambos modelos, siendo el modelo ARIMA  $(1,0,0)(1,1,0)[4]$  un poco mejor que el modelo ARIMA2  $(1,0,3)(0,1,1)[4]$ .

Si prestamos atencion a las predicciones del modelo ARIMA, observamos como en los Q4 el modelo estima unas ventas notablemente mayores a las de los otros trimestres.


fventas.arima

##	Point Forecast	Lo 70	Hi 70	Lo 90	Hi 90
## 2015 Q2	63.87911	50.45181	80.87998	43.92546	92.89694
## 2015 Q3	66.62150	48.38795	91.72582	40.10623	110.66672
## 2015 Q4	108.60618	74.58567	158.14435	59.82079	197.17730
## 2016 Q1	82.59056	54.43531	125.30838	42.61854	160.05242
## 2016 Q2	67.25047	39.94798	113.21288	29.42440	153.70321
## 2016 Q3	70.21197	38.76557	127.16753	27.35346	180.22297
## 2016 Q4	115.28329	60.25182	220.57817	41.16676	322.83906
## 2017 Q1	87.55462	43.85305	174.80683	29.22308	262.32045

## Comparacion ETS y ARIMA

Vamos a comparar los graficos de los dos modelos elegidos:

```
grid.arrange(plotets,plotarima,ncol=2)
```



## ANALISIS DE INTERVENCION

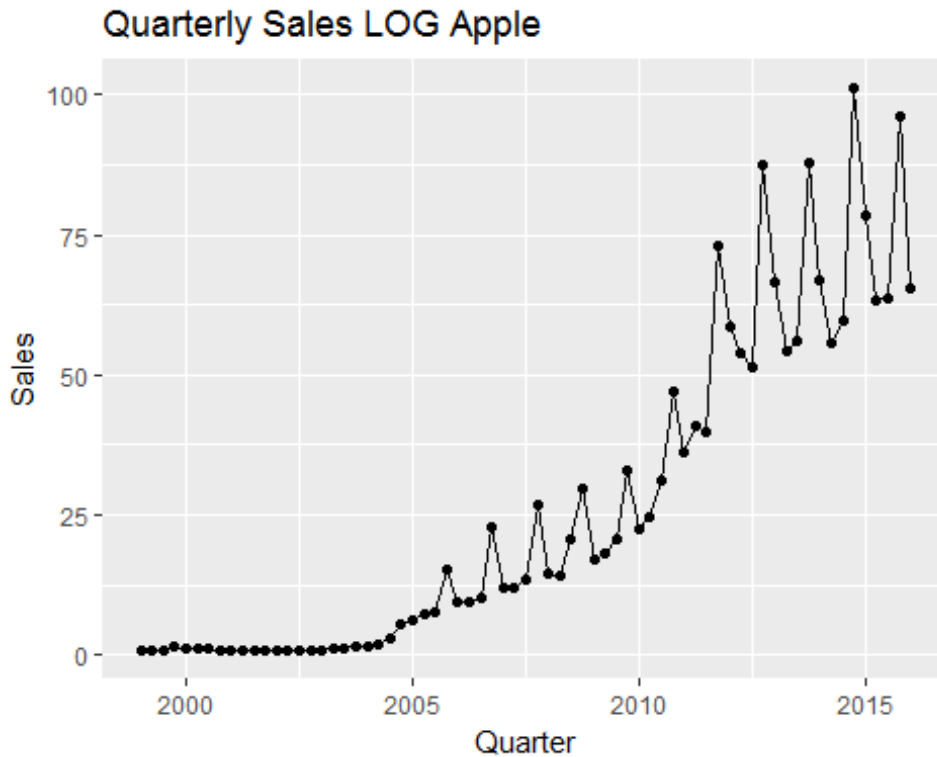
vamos a comprobar si podemos mejorar el modelo utilizando un modelo ARIMAX.

Para ello tenemos ver si hay que practicar analisis de intervencion.

Lo primero es observar el grafico de crecimiento (graficamos zlVentas)

```
ggplot(df_new1)+geom_point(aes(x=time,y=value))+geom_line(aes(x=time,y=value))+ylab("Sales")+ggtitle("Quarterly Sales LOG Apple")+xlab("Quarter")
```

```
## Don't know how to automatically pick scale for object of type yearqtr.
Defaulting to continuous.
```

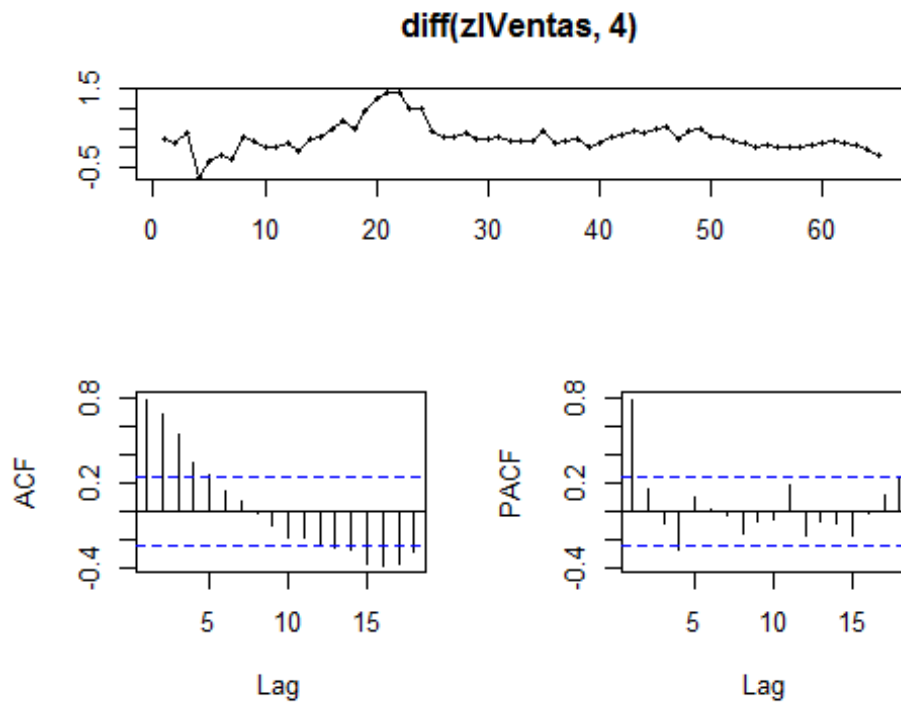


Se puede observar un incremento de las ventas notable en el Q3 de 2004. Esto coincide con el lanzamiento de la 4ª generación de iPods. Podemos ver el escalon que tiene lugar en 2004 y que se mantiene en el tiempo. <https://www.cnet.com/pictures/the-complete-history-of-apples-ipod/>

En el Q4 de 2010 comienza el verdadero crecimiento exponencial de la compañía como consecuencia del lanzamiento de iPhone 4, que marco un antes y un después en la telefonía móvil y en la trayectoria de Apple. Podríamos considerar aquí otro escalón, sin embargo, teniendo en cuenta que después del lanzamiento del iPhone 4 cada Q4 Apple obtiene un crecimiento de las ventas considerable con cada nuevo lanzamiento, considero que la suma de las intervenciones de Apple forman parte intrínseca de la tendencia en sus ventas y, por tanto, las asumo como hechos normales.

Consideraré únicamente el escalón que provoca el lanzamiento de la cuarta generación de iPods a la hora de estimar el modelo ARIMAX, ya que se trata de la intervención que da lugar al germen de crecimiento de las ventas de Apple.

```
tsdisplay(diff(zlVentas,4))
```



## ARIMAX

```
fitARIMAX=arimax(log(zVentas),order=c(1,0,0),
                 seasonal=list(order=c(1,1,0),period=4),
                 xtransf=data.frame(iPod2004=1*(seq(zVentas)==25)),
                 transfer=list(c(1,0)),
                 method='ML')
```

fitARIMAX

```
##
## Call:
## arimax(x = log(zVentas), order = c(1, 0, 0), seasonal = list(order = c
##      0), period = 4), method = "ML", xtransf = data.frame(iPod2004 = 1
##      * (seq(zVentas) ==
##      25)), transfer = list(c(1, 0)))
##
## Coefficients:
##          ar1      sar1 iPod2004-AR1 iPod2004-MA0
##          0.8952 -0.4468          1.0118          0.5173
## s.e.    0.0585  0.1513          0.0344          0.1849
##
## sigma^2 estimated as 0.04209: log likelihood = 9.72, aic = -11.45
```


Obtenemos un modelo con menos AIC que el anterior ARIMA, aunque no es del todo correcto comparar ARIMA y ARIMAX en criterios de información.



Graficamos el modelo

```
plot(log(zVentas), ylab="zlVentas")
points(fitted(fitARIMAX))

## Warning in fitted.Arima(fitARIMAX): Métodos incompatibles ("Ops.zoo",
## "Ops.ts") para "-"
```



## Outliers

### Aditivos

Tiene valores atipicos aditivos el modelo?

```
detectAO(fitARIMAX)

##           [,1]      [,2]      [,3]
## ind      7.000000  8.000000 24.000000
## lambda2  4.620476 -5.067049  3.603647
```

El modelo detecta 2 aditivos. Tendremos que comprobar si efectivamente se trata de outliers o si se trata de intervenciones. En este caso no se trata de intervenciones

### Innovativos


Tiene valores atipicos innovativos el modelo?

```
detectIO(fitARIMAX)
```

```
##           [,1]      [,2]
## ind      8.000000 24.000000
## lambda1 -5.818846  3.464391
```

Existe un valor atípico innovativo. Los valores atípicos innovativos afectan al error y empeoran los modelos.

```
autoplot(fitARIMAX$residuals)
```



La caída que hay al final del año 2000, en el Q4, contrasta mucho con el resto de la tendencia. Hemos visto que el Q4 es el trimestre con mas ventas año tras año y que sirve de propulsor para el crecimiento en la facturación de Apple.

Vamos a estimar el modelo ARIMAX para ver si mejora definiendo el outlier innovativo

```
fitARIMAX2=arimax(log(zVentas),order=c(1,0,0),
                  seasonal=list(order=c(1,1,0),period=4),
                  xtransf=data.frame(iPod2004=1*(seq(zVentas)==25)),
                  transfer=list(c(1,0)),
                  io=c(8,24,23),
                  method='ML')

fitARIMAX2

##
## Call:
## arimax(x = log(zVentas), order = c(1, 0, 0), seasonal = list(order = c
```

```
(1, 1,
##      0), period = 4), method = "ML", io = c(8, 24, 23), xtransf = data.
frame(iPod2004 = 1 *
##      (seq(zVentas) == 25)), transfer = list(c(1, 0)))
##
## Coefficients:
##          ar1          sar1          IO-8          IO-24          IO-23 iPod2004-AR1 iPod2004
-MA0
##          0.8354 -0.1989 -0.5619  0.7548  0.5117          1.0133          1.
2165
## s.e.  0.0789  0.1525  0.0919  0.1900  0.1315          0.0084          0.
2432
##
## sigma^2 estimated as 0.02341: log likelihood = 29.21, aic = -44.42
```

El AIC del modelo disminuye. El criterio de información del modelo mejora mucho AIC=-44.2

### Aditivos

Tiene valores atípicos aditivos el modelo?

```
detectA0(fitARIMAX2)
```

```
##          [,1]
## ind      7.000000
## lambda2  3.712198
```

El modelo detecta 2 aditivos. Tendremos que comprobar si efectivamente se trata de outliers o si se trata de intervenciones. En este caso no se trata de intervenciones

### Innovativos

Tiene valores atípicos innovativos el modelo?

```
detectIO(fitARIMAX2)
```

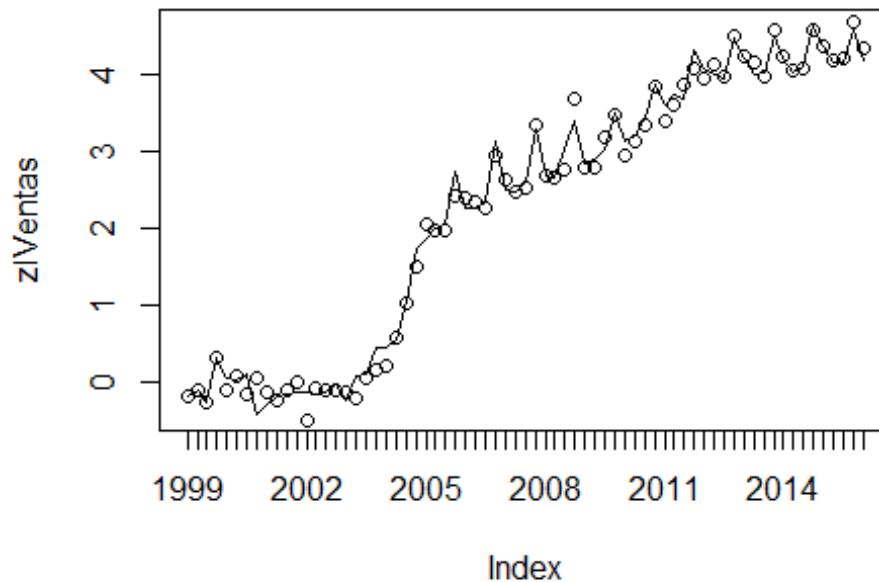
```
## [1] "No IO detected"
```

Se eliminan los valores atípicos innovativos completamente.

Graficamos el modelo

```
plot(log(zVentas), ylab="zVentas")
points(fitted(fitARIMAX2))

## Warning in fitted.Arima(fitARIMAX2): Métodos incompatibles ("Ops.zoo",
## "Ops.ts") para "-"
```



## Conclusiones

A lo largo de la practica hemos comprobado que los tres modelos, ETS, ARIMA y ARIMAX2, se ajustan bastante bien aunque con diferencias en función del peso que le están dando a la información. En funcion del objetivo que tengamos dentro del negocio, utilizaremos un modelo u otro.

El ETS tiene mucho mas en cuenta la información mas reciente. En este sentido, es posible que convenga utilizar el modelo ETS para predecir a muy corto plazo, a 1 o 2 trimestres: dado que el ETS tiene en cuenta que las ventas del iphone 7 no fueron muy buenas y que las ventas cayeron (última información disponible en la serie), si no se espera el lanzamiento de un producto innovador por parte de Apple parece que convendría utilizar este modelo para hacer la predicción.

A la hora de predecir periodos mas lejanos, convendra utilizar el modelo ARIMAX2, puesto que ha mejorado el ARIMA que teníamos.

Lo ideal, dado el objeto de análisis y la incertidumbre inherente a cualquier prediccion, seria combinar ambos modelos para fundamentar mejor las decisiones.